

Documento de Diseño Técnico: Plataforma MLOps para Pricing Intelligence

Status: En proceso de revisión ▾

Equipo: Emanuel Flores Martínez , Mario Javier Soriano Aguilera ,
David Alberto Serrano García

Fecha de Creación: 3 may 2026

Fecha de Actualización: 3 may 2026

Acceso: Confidencial ▾

1. Contexto de Negocio y Objetivos del Proyecto

La organización depende del sistema de *Pricing Business Intelligence* para sugerir precios objetivos (Target), mínimos (Floor) y de inicio (Start) a nivel de Número de Parte (KPN) y Segmento de Distribuidor. Actualmente, los modelos analíticos son precisos, pero el entorno comercial cambia rápidamente. El objetivo de este proyecto es construir una capa de MLOps que actúe como un "freno de emergencia y auditor" automatizado. Esta infraestructura garantizará que las recomendaciones de precios sean reproducibles, auditables y se ajusten proactivamente a la volatilidad del mercado, protegiendo los márgenes comerciales y el *revenue* sin generar costos excesivos de infraestructura en la nube.

2. Alineación entre Arquitectura Técnica y Valor de Negocio

La arquitectura propuesta se basa en decisiones técnicas específicas que resuelven directamente las preocupaciones de los stakeholders:


- **Modelo de Costos "Serverless" (Pago por Uso):** El negocio requiere eficiencia. En lugar de tener servidores costosos encendidos 24/7, utilizamos **Azure Functions (Flex Consumption)** y **Azure SQL Serverless**. El sistema solo consume presupuesto durante los minutos exactos en que calcula precios o evalúa desviaciones, logrando una reducción drástica del costo operativo mensual.
- **Seguridad Nivel Enterprise:** Los datos de márgenes y costos son altamente confidenciales. Todo el tráfico de datos se aísla mediante **VNet y Private Endpoints**. Ningún componente tiene salida a internet público.
- **Decisiones Ponderadas por Impacto Financiero:** El mecanismo de "Drift" (desviación de datos) no trata todos los productos igual. Una desviación en un producto de bajo volumen no detendrá la operación, pero una anomalía en un Segmento de Distribuidor clave (Disty Segment) activará una alerta crítica (Semáforo

Rojo).

- **Trazabilidad Absoluta:** Para auditoría, el sistema registra la "Espina Dorsal" de cada ejecución en tablas SQL temporales. Podemos demostrar con evidencia irrefutable qué versión de código, qué datos y qué configuración generaron un precio específico hace seis meses.

3. Arquitectura de Servicios y Topología en Azure

El siguiente diagrama detalla la topología de red aislada (Hub-and-Spoke) y los servicios serverless utilizados para garantizar seguridad y bajo costo operativo.



Topología de Red (Hub-and-Spoke) y Flujo de Conectividad:

La arquitectura utiliza un modelo Hub-and-Spoke. El **Hub VNet** contiene los componentes de seguridad (**Azure Private DNS Zones**) y de despliegue (**DevOps Agents Self-Hosted**), y se conecta al **Spoke VNet (Entorno de Producción)** mediante VNet Peering.

El **Spoke VNet** se divide en:

- **Subred: Integración (Serverless):** Aloja **Azure Functions Flex Consumption** (Motor de Drift y Orquestación).
- **Subred: AML Compute:** Aloja **Azure ML Serverless Compute** (Entrenamiento, Validación y Scoring).
- **Subred: Private Endpoints (Capa de Datos Cerrada):** Aloja **Azure Data Lake Storage Gen2 (ADLS)**, **Azure SQL Database Serverless** (Tablas de Auditoría), **Azure Key Vault** (Secretos y Sales de Encriptación), y **Azure Container Registry** (Imágenes de Modelos).

Key Vault, y Azure Container Registry (ACR).


Los flujos principales son orquestados por Azure Data Factory (ADF) que inicia la ingesta y dispara el flujo hacia Azure Functions (AF) para la coordinación de la validación y el *scoring*.

3.1 Diccionario de Servicios y Responsabilidades

Componente Azure	Responsabilidad en el Proyecto MLOps
Azure Data Factory (ADF)	Orquestador principal. Se encarga de la ingesta de datos desde los sistemas fuente, aplica el enmascaramiento/anonimización de IDs de clientes y programa las ejecuciones diarias/semanales.
Azure Data Lake Storage (ADLS)	Almacenamiento inmutable y versionado. Guarda los datos crudos (<i>raw</i>), las características procesadas (<i>curated</i>) y los resultados finales de precios (<i>model_output_snapshot</i>).
Azure Functions (Flex)	Cerebro de las reglas de negocio. Calcula métricas estadísticas (PSI, KS), determina el estado del Semáforo y registra los eventos en la base de datos.
Azure Machine Learning (AML)	Motor de ejecución ML. Aloja el registro de modelos, ejecuta la validación de calidad de datos con <i>Great Expectations</i> y corre el modelo base.
Azure SQL (Serverless)	La "Espina Dorsal" de auditoría. Almacena las tablas temporales de <i>model_run_log</i> , el historial de Drift y los metadatos de los snapshots.
Azure Key Vault	Bóveda de seguridad. Almacena las llaves criptográficas utilizadas para anonimizar los datos confidenciales antes de que toquen el Data Lake.

4. Flujo del Proceso Completo (Sequence Flow)

Este flujo de secuencia ilustra el paso a paso de una ejecución diaria del sistema de *Pricing*, mostrando cómo interactúan los componentes técnicos y dónde actúan las compuertas de calidad.



1. **ADF** ingesta datos y hasha IDs confidenciales, enviándolos a **ADLS**.
2. **ADF** crea un registro en `model_run_log` en **SQL** (Estado: STARTED).
3. **ADF** inicia el flujo de Machine Learning en **Azure Functions (AF)**.
4. **AF** ordena a **AML** ejecutar la validación (*Great Expectations*).
5. **AML** guarda las métricas de calidad en `data_quality_log` en **SQL**.
6. **AF** ordena a **AML** extraer y transformar características (Features).
 - **AML** guarda Features versionadas (*curated*) en **ADLS**.
7. **AF** calcula estadísticos vs Baseline (Drift) en **SQL**.
 - *Nota:* El sistema evalúa si se activa el Semáforo Rojo; si es así, pausa la operación. Si es Verde/Amarillo, continúa.
8. **AF** ordena a **AML** ejecutar el modelo Campeón (Scoring).
9. **AML** guarda los precios generados (Parquet immutable) en **ADLS**.
10. **AML** registra metadatos del snapshot en **SQL**.
11. **AF** cierra el `model_run_log` en **SQL** (Estado: COMPLETED).

5. Enfoque Paso a Paso y Cronograma (Roadmap)

Para garantizar un despliegue seguro, el equipo de ingeniería ejecutará el proyecto en cuatro fases secuenciales.

Roadmap de Implementación MLOps (Fases del Proyecto)

- **Fase 1: Cimientos**
 - Topología VNet Hub-Spoke & Private Links
 - Configuración Key Vault & Identidades (UAMIs)
- **Fase 2: Auditoría**
 - Despliegue Azure SQL Serverless
 - Creación de Esquemas (`model_run_log`, `snapshots`)
- **Fase 3: Calidad & Drift**
 - Integración *Great Expectations* en AML
 - Desarrollo de Lógica de Drift en Azure Functions

- **Fase 4: Orquestación**
 - Pipelines ADF & CI/CD con Terraform/Bicep
 - Pruebas E2E, Datos Sintéticos & Cierre

6. Validación, Calidad del Trabajo y Experiencia del Desarrollador

No probaremos código en producción. La calidad técnica se asegura mediante:

- **Datos Sintéticos para Desarrollo:** Los ingenieros trabajarán con un conjunto de datos simulado (generado a partir de distribuciones reales) en sus entornos locales. Los datos confidenciales de precios nunca salen del entorno de producción.
- **Integración Continua (CI):** Cada cambio en el código o en la infraestructura debe pasar pruebas automáticas en menos de 60 segundos antes de ser fusionado.
- **Validación de Datos (Great Expectations):** Antes de que el modelo calcule un solo precio, un contenedor evalúa el dataset contra reglas contractuales. Si los datos de entrada vienen corruptos desde el origen, el proceso se aborta automáticamente (Quality Gate).

7. Gestión de Riesgos: Mecanismo de Rollback

Si una nueva versión del modelo es promovida a producción pero el negocio detecta un comportamiento errático en los precios:

1. **Sin pérdida de historial:** El sistema detiene la generación de precios automáticamente o vía intervención manual.
2. **Reversión en < 15 minutos:** Se reasigna la etiqueta de "Producción" a la versión anterior del modelo (el último "campeón" estable) en el registro de Azure ML, sin alterar código.
3. **Corrección Transparente:** Los precios erróneos no se borran (para fines de auditoría), pero se marcan como "sustituidos" (**superseded**) en Azure SQL. El sistema recalcula los precios con el modelo seguro y los publica.

8. Próximos Pasos: Definición de Umbrales del Semáforo

Para calibrar el sistema, el equipo de Datos y Pricing tiene el siguiente plan de acción:

1. El equipo de datos correrá el algoritmo sobre los últimos 6 meses de datos históricos de ventas.
2. Identificaremos los umbrales estadísticos exactos (PSI, KS) donde históricamente ocurrieron anomalías de negocio (ej. compresión de márgenes).
3. Presentaremos una propuesta concreta a los líderes de negocio: *"Si la volatilidad supera el X%, sugerimos detener el modelo (Rojo)"*. Los stakeholders revisarán y aprobarán estos límites de tolerancia al riesgo.

9. Anexo: Especificaciones de Implementación sobre Datos Reales

Tras el perfilado de los esquemas de producción (**masked_input_dataset.csv** con ~234k filas

y `masked_output_recommendations.csv` con ~8.3k filas), se establecen las siguientes reglas exactas de implementación para las capas de calidad de datos, cómputo y detección de anomalías.

9.1 Dimensionamiento de Cómputo (Validación Serverless)

- **Consumo de Memoria:** Mediante el uso de tipos de datos optimizados y lecturas proyectadas en PyArrow (leyendo archivos Parquet directamente de ADLS), el dataset completo de entrada ocupa **~7 MB en memoria**.
- **Decisión Arquitectónica:** Esto valida definitivamente el uso de **Azure Functions (Flex Consumption)**. El procesamiento de *Drift* completo tomará menos de 30 segundos, muy por debajo de los límites del servicio, sin requerir particionado complejo (*chunking*) ni clústeres dedicados.

9.2 Compuertas de Calidad Críticas (Great Expectations)

El paso de validación (`model_inputs.json` y `curated_features.json`) no detendrá el flujo por anomalías esperadas, pero actuará como un freno de emergencia ante corrupciones críticas. Las 4 reglas iniciales son:

1. **Tolerancia Inteligente a Nulos (Costos):** La columna `current_cost_orders` tiene un 49% de nulos de forma natural.
 - *Regla:* Alerta informativa (Warning) si la integridad baja al 45%. **Falla Crítica** (detiene el pipeline) solo si la integridad cae por debajo del 30% (indicando una falla en el pipeline de origen).
2. **Contrato de Granularidad Única:** La combinación de llaves [`kpn`, `vpareadescription`, `distysegment`] debe ser 100% única en el dataset de salida para evitar duplicación de proyecciones de *revenue* en sistemas downstream.
3. **Invarianza de Monotonicidad (Percentiles):** El modelo matemáticamente siempre debe cumplir que `P0_PRICE <= P20_PRICE <= P50_PRICE <= P85_PRICE <= P100_PRICE`. Cualquier violación a esta regla indica una falla interna del algoritmo.
4. **Consistencia del Piso de Margen (Business Rule):** Si la bandera `P20_Was_Adjusted` es Verdadera, el precio ajustado debe ser estrictamente mayor o igual a `Min_P20_for_5pct_margin`. Esta regla garantiza que el modelo no venda por debajo del margen del 5% permitido.

9.3 Configuración del Semáforo de Desviación (Drift)

Además de detectar cambios en la distribución de datos (mediante métodos estadísticos PSI y Kolmogorov-Smirnov), el motor de Drift monitoreará "Señales de Negocio", que son indicadores tempranos de compresión de márgenes o pérdida de precisión.

Métrica / Columna	Método Estadístico	Umbral (Amarillo / Rojo)	Justificación de Negocio
-------------------	--------------------	--------------------------	--------------------------

rslpriceusd y quantity	PSI (Índice de Estabilidad) en contenedores logarítmicos	0.10 / 0.25	Detecta cambios masivos en el volumen de ventas o rangos de precio de reventa.
elasticity_mean	KS (Kolmogorov-Smirnov)	0.05 / 0.15	Altera si cambia el comportamiento elástico del mercado (captura mejor las colas de la distribución).
Compresión del Spread (P85 - P20)	KS sobre la diferencia	0.10 / 0.20	Si el rango de precios sugeridos se comprime abruptamente, indica pérdida de sensibilidad del modelo.
Tasa de P20_Was_Adjusted	Prueba Z de proporciones (Control Chart)	$z > 2.0$ / $z > 3.5$	Métrica Crítica: Históricamente, solo el 0.31% de las recomendaciones tocan el piso del 5% de margen. Si esta tasa sube, significa que los costos están superando los precios de mercado.

9.4 Resiliencia ante Evolución de Esquemas

Cuando el negocio agregue nuevos niveles de jerarquía (ej. hier_level7) o elimine costos redundantes, el sistema está diseñado para no romperse:

1. **Tablas de Auditoría Inmutables:** El esquema SQL `model_output_snapshot_metadata` registra la versión del contrato de datos (`output_schema_version`). Las adiciones son retrocompatibles.
2. **Versionado de Baselines:** Un cambio de columnas forzaré la creación de un nuevo identificador de línea base histórica (ej. `baseline_2026Q3_v3.1`). Durante la transición, el motor de Drift comparará exclusivamente la intersección de columnas conocidas hasta reunir suficiente historial de la nueva variable.